MAIL GUARD · MINERÍA DE DATOS

Del dato sucio a la predicción

Proceso completo de minería con RapidMiner: 100.000 correos, depuración, árbol de decisión y visualización.



Proyecto Mail Guard · Unidades Tecnológicas de Santander · Noviembre 2026

EL OBJETIVO

¿Este correo es seguro, sospechoso o peligroso?

Entrenar un modelo que prediga el veredicto de un correo a partir de 16 características que Mail Guard ya extrae del mensaje: remitente, enlaces, lenguaje y dominio.

60,2 %

Seguro

Remitente conocido, dominio con años de antigüedad, sin presión ni enlaces raros.

24,8 %

Sospechoso

Algunas señales: dominio reciente, enlaces acortados, tono de urgencia.

15,0 %

Peligroso

Imita marcas, pide credenciales, enlaces a direcciones IP.

Tarea: clasificación supervisada multiclase · **Herramienta:** RapidMiner (Altair AI Studio 2026) · **Etiqueta:** veredicto

EL PROCESO

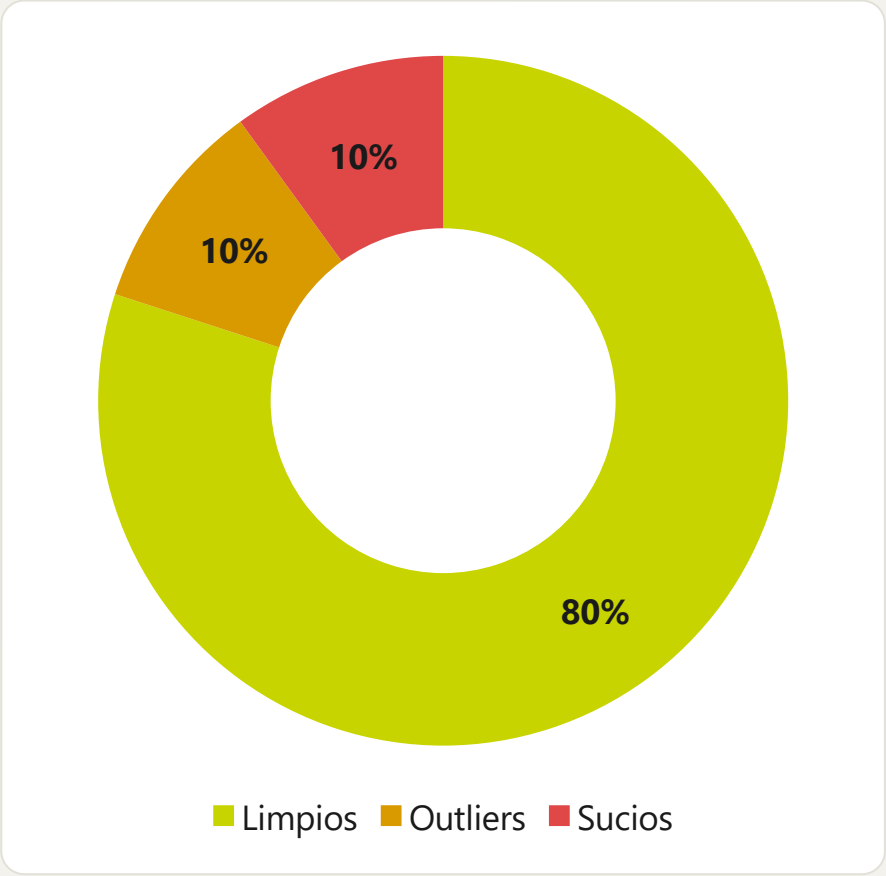
Seis fases, de la base de datos al panel



Las fases 1 a 5 son los cinco subprocesos del archivo mail-guard-mineria.rmp; la fase 6 combina los gráficos de RapidMiner y la página «Minería» del panel.

LOS DATOS

100.000 correos sintéticos, sucios a propósito



Parte	Filas	%	Cómo se generó
Limpios y válidos	80.000	80 %	Perfil distinto por clase
Outliers	10.000	10 %	Extremos o imposibles
Celdas vacías	4.000	4 %	NULL real en PostgreSQL
Texto «NULL»	3.000	3 %	Hay que declararlo faltante
Duplicados exactos	3.000	3 %	Copias de registros limpios

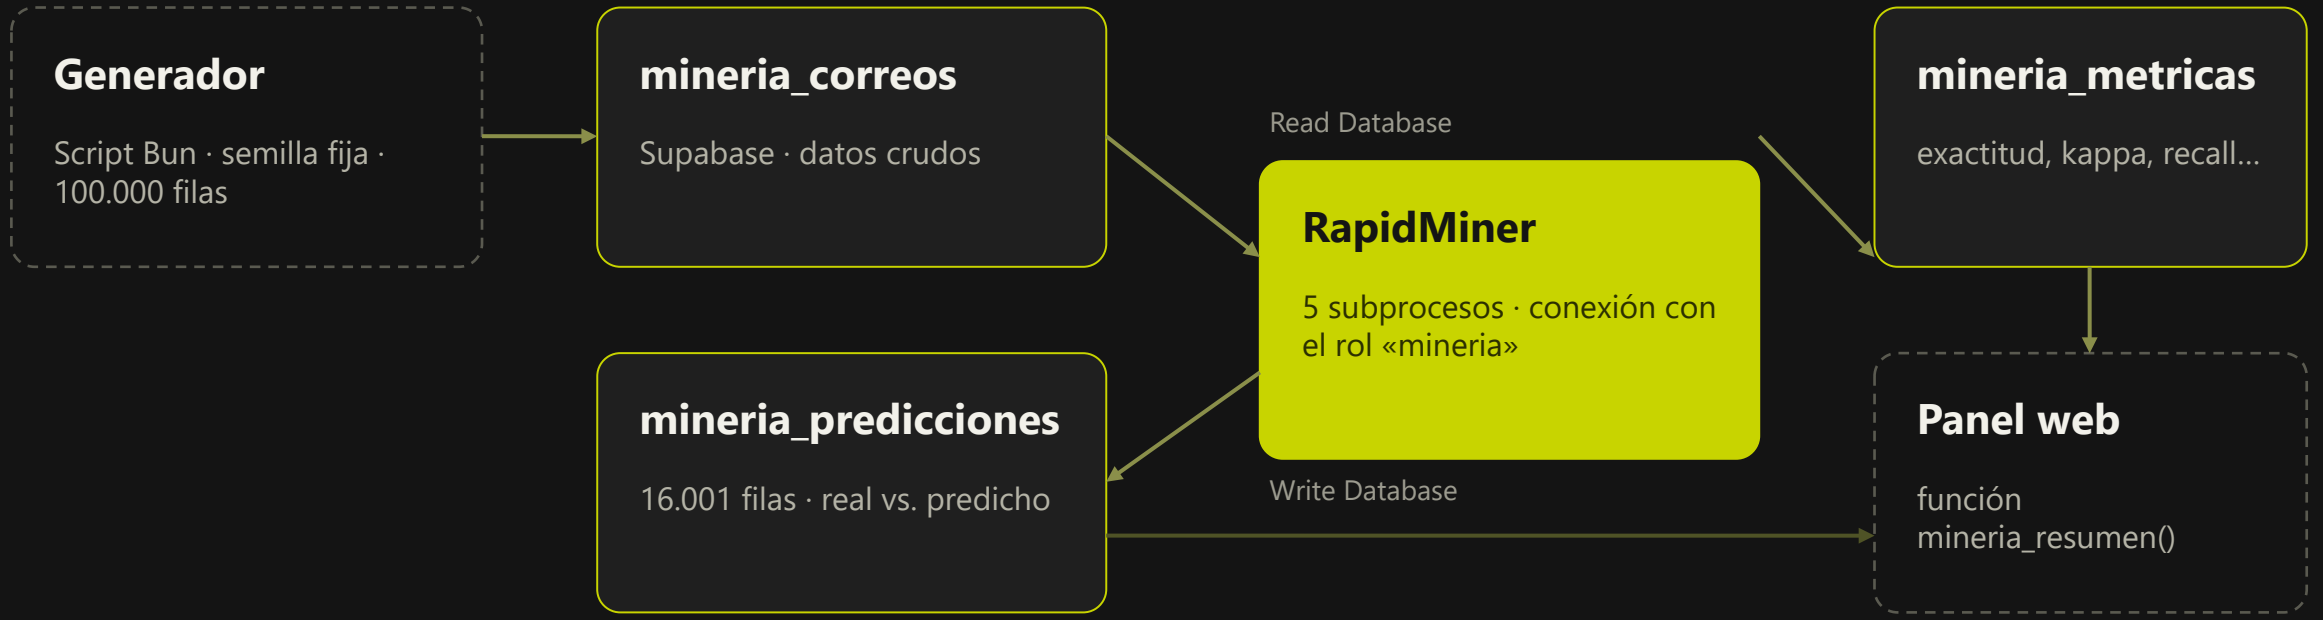
16 VARIABLES PREDICTORAS

tipo de dominio · proveedor · longitud de asunto y cuerpo · nº de enlaces · enlaces acortados · enlaces con IP · imita una marca · punycode · palabras de urgencia · pide credenciales · nombre coincide con dominio · adjunto · antigüedad del dominio · hora de envío · % de mayúsculas

Semilla fija: el script genera siempre el mismo archivo, así cualquiera puede reproducir el resultado.

ARQUITECTURA

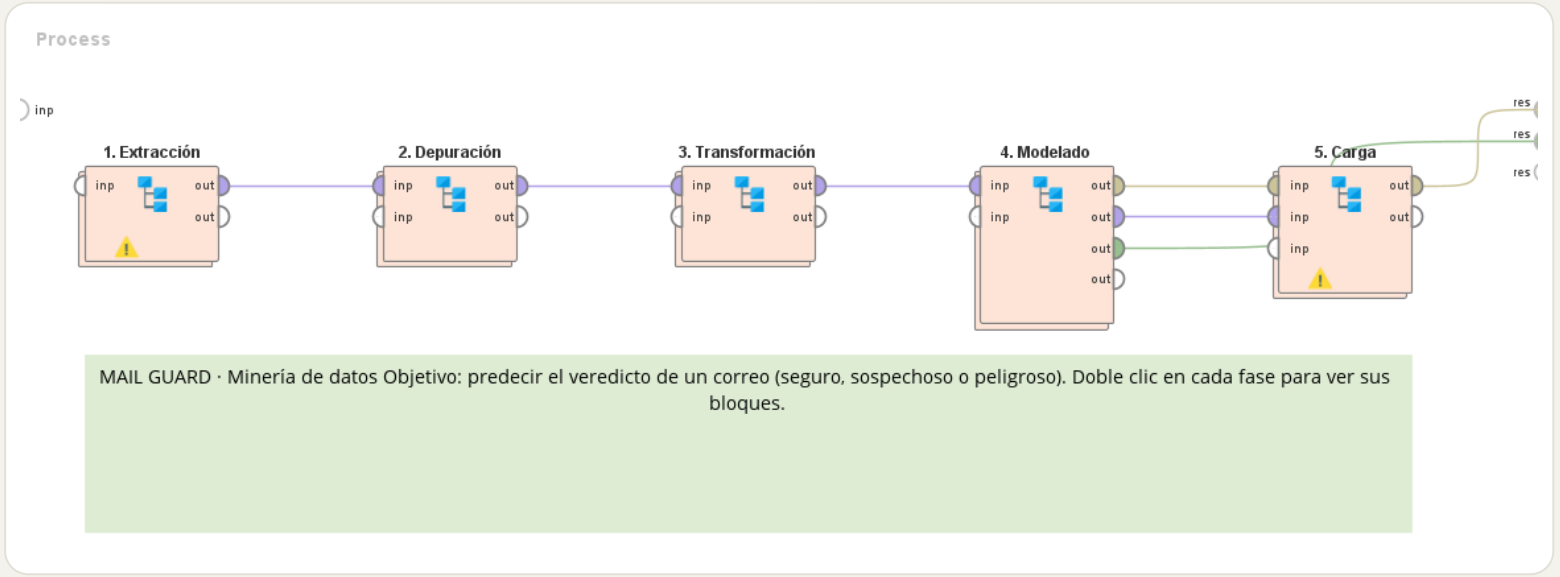
RapidMiner lee y escribe directamente en Supabase



El rol «mineria» solo puede tocar las tablas mineria_* (nunca los datos de los usuarios) · el panel no descarga las 100.000 filas: una función SQL le entrega los agregados.

EN RAPIDMINER

Un proceso principal, cinco subprocesos



Doble clic en cada subproceso abre sus bloques. Cada fase lleva una nota que explica qué hace — el diagrama se lee solo.

1. Extracción

Conexión · Limpiar resultados previos · Leer 100.000 correos

2. Depuración

Eliminar duplicados · Declarar NULL · Filtrar vacíos · Filtrar outliers

3. Transformación

Quitar columnas no predictivas · Definir etiqueta e ID

4. Modelado

División 80-20 · Árbol de decisión · Predecir · Evaluar

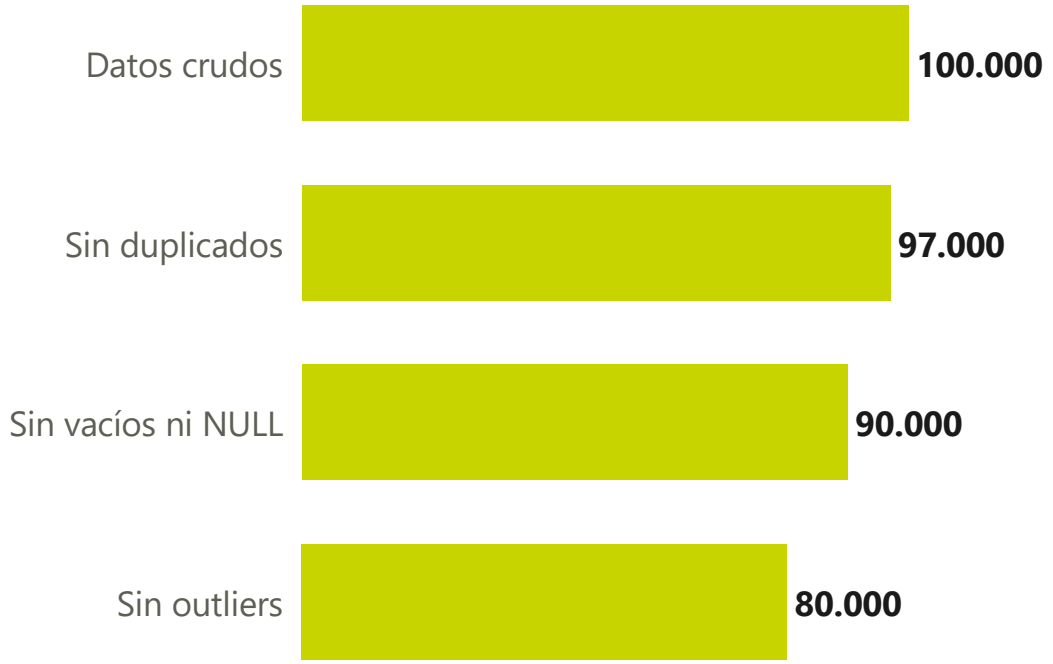
5. Carga

Guardar métricas · Guardar predicciones

FASE 2 · DEPURACIÓN

De 100.000 a 80.000 registros confiables

Filas que sobreviven a cada paso



Eliminar duplicados
Remove Duplicates · todas las columnas
−3.000

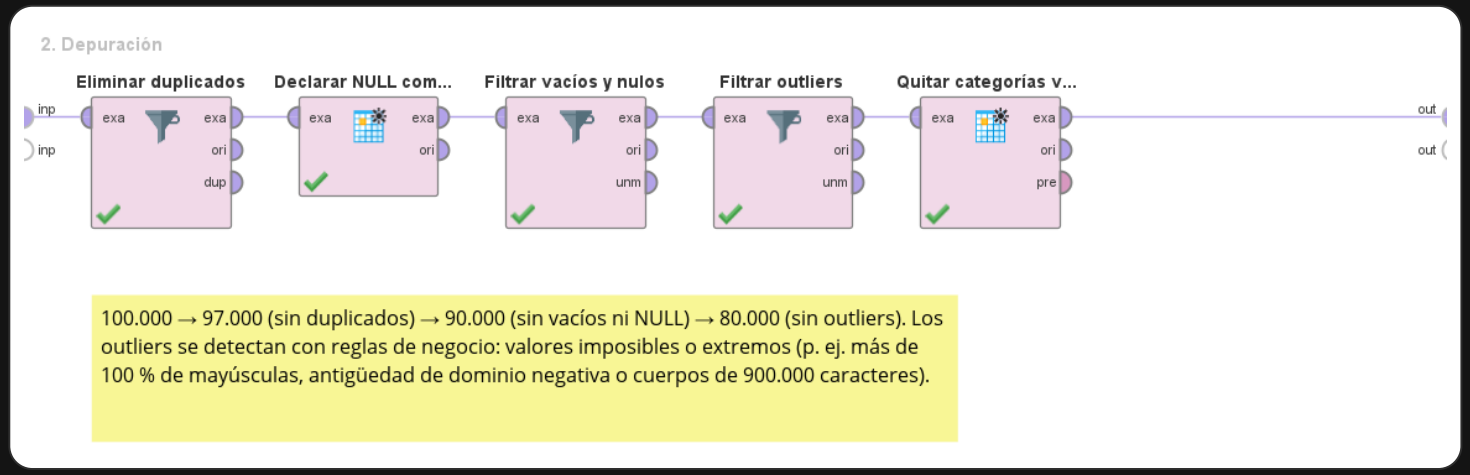
Declarar NULL como faltante
Declare Missing Value · texto «NULL» → «?»
0

Filtrar vacíos y nulos
Filter Examples · no_missing_attributes
−7.000

Filtrar outliers
Filter Examples · 9 reglas de negocio
−10.000

DEPURACIÓN · OUTLIERS

Outliers detectados con reglas de negocio



Subproceso «2. Depuración» en RapidMiner

OUTLIERS REALES DEL DATASET

900.000
caracteres en un cuerpo

1.000 %
de mayúsculas

−5.000
días de antigüedad

2.000
enlaces en un correo

SE CONSERVA SI…

longitud del asunto	**≤ 150**
longitud del cuerpo	**≤ 5.000**
enlaces (total, acortados, IP)	**≤ 25**
palabras de urgencia	**≤ 12**
antigüedad del dominio	**1 – 9.000 días**
% de mayúsculas	**≤ 100**

¿Por qué reglas y no un detector por distancias? Detect Outlier (Distances) compara cada fila con todas las demás: con 100.000 filas son 10.000 millones de comparaciones. Las reglas son exactas, rápidas y explicables.

FASES 3 Y 4 · TRANSFORMACIÓN Y DIVISIÓN

80 % para aprender, 20 % para comprobar

Entrenamiento · 80 % | **Prueba · 20 %**

63.999

correos entrenan el árbol de decisión

16.001

correos que el modelo nunca vio sirven para verificarlo

60 / 25 / 15

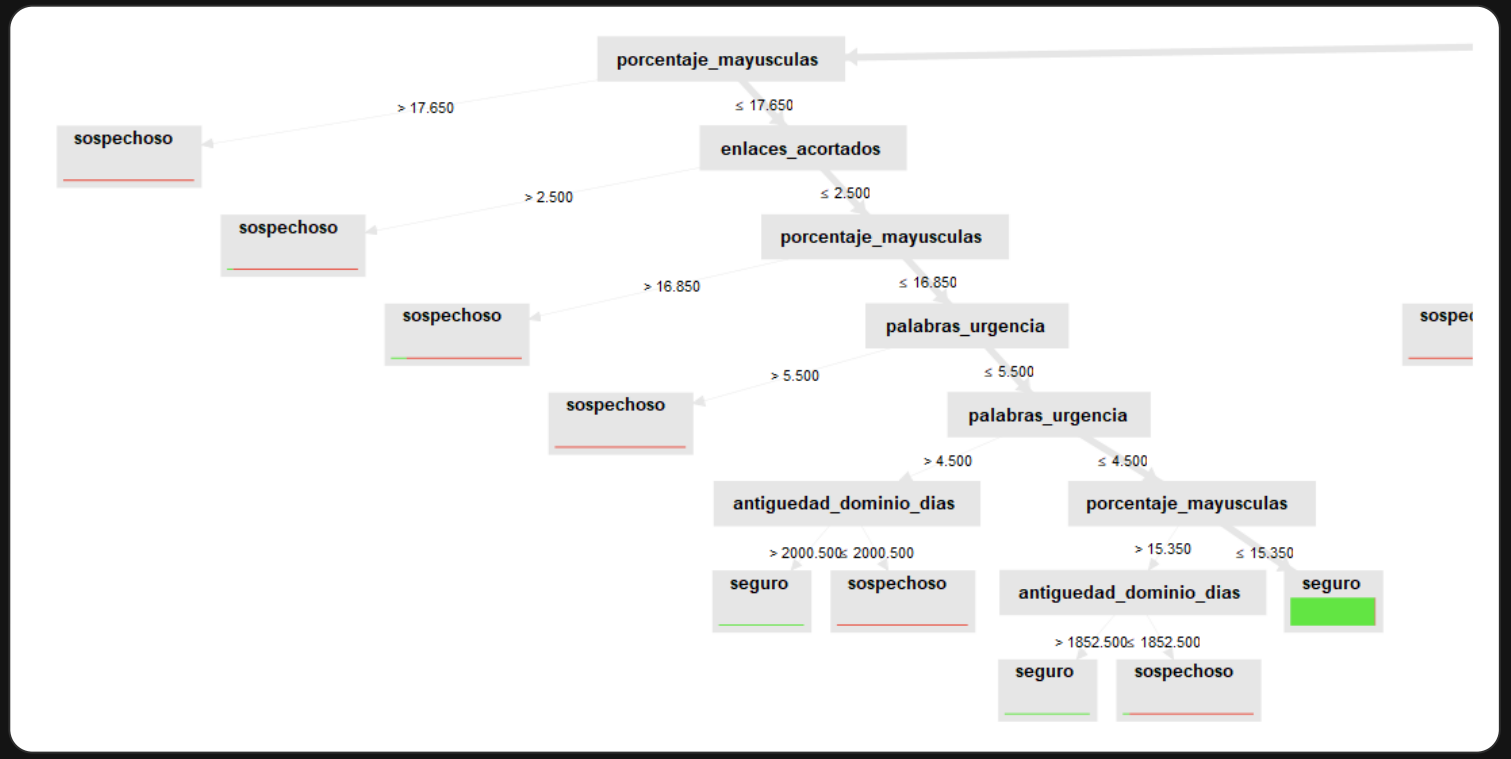
misma proporción de clases en ambas partes (muestreo estratificado)

Transformación previa

Se quitan fecha_analisis y dominio_remitente (identifican al correo, no lo describen: el modelo memorizaría en vez de aprender). «veredicto» pasa a ser la etiqueta (label) e «id_correo» el identificador (id): viaja con cada fila pero no se usa para predecir.

FASE 4 · MODELADO

Un árbol de decisión que se puede leer



Fragmento del árbol entrenado en RapidMiner (profundidad 10)

CONFIGURACIÓN

Criterio	**gain ratio**
Profundidad máx.	**10**
Poda y pre-poda	**activadas**
Semilla	**1992**

¿POR QUÉ UN ÁRBOL?

Cada predicción se explica con reglas «si… entonces», igual que Mail Guard explica sus veredictos. Las primeras divisiones usan % de mayúsculas, enlaces acortados, palabras de urgencia y antigüedad del dominio.

LO QUE APRENDIÓ EL MODELO

El phishing deja huellas medibles

Variable (promedio)	Seguro	Sospechoso	Peligroso
Imita una marca	2 %	30 %	**75 %**
Pide credenciales	4 %	29 %	**80 %**
Enlaces acortados (promedio)	0,1	1,4	**3,6**
Palabras de urgencia (promedio)	0,4	1,8	**3,5**
Mayúsculas en el texto	6 %	14 %	**24 %**
Antigüedad del dominio	2.509 días	428 días	**67 días**

67 días

es la edad promedio del dominio de un correo peligroso. Los legítimos superan los 6 años.

8 de cada 10

correos peligrosos piden credenciales; solo 4 de cada 100 seguros lo hacen.

VALIDACIÓN · 20 % DE PRUEBA

Resultados sobre correos que el modelo nunca vio

94,31 %

de exactitud (accuracy): 15.091 aciertos de 16.001 correos de prueba.

0,897	5,69 %	92,21 %	91,87 %
Kappa	**Error**	**Recall**	**Precisión**
concordancia casi perfecta	de clasificación	promedio ponderado	promedio ponderada

EVIDENCIA · PERFORMANCE (CLASSIFICATION) EN RAPIDMINER

accuracy: 94.31%

	true peligroso	true seguro	true sospechoso	class precision
pred. peligroso	2172	0	269	88.98%
pred. seguro	1	9407	189	98.02%
pred. sospechoso	227	224	3512	88.62%
class recall	90.50%	97.67%	88.46%	

Mismo resultado en cada ejecución: semilla fija en la división y en el árbol.

MATRIZ DE CONFUSIÓN

Casi nunca deja pasar un phishing como seguro

Real ↓ Predicho →	Seguro	Sospechoso	Peligroso	Recall
● **Seguro**	**9.407**	224	0	97,7 %
● **Sospechoso**	189	**3.512**	269	88,5 %
● **Peligroso**	1	227	**2.172**	90,5 %
Precisión	98,0 %	88,6 %	89,0 %	

Diagonal = aciertos. Filas: veredicto real · columnas: lo que predijo el modelo.

1 de 2.400 correos peligrosos se clasificó como seguro: el error más costoso casi no ocurre.

0 correos seguros se marcaron como peligrosos: no hay falsas alarmas graves.

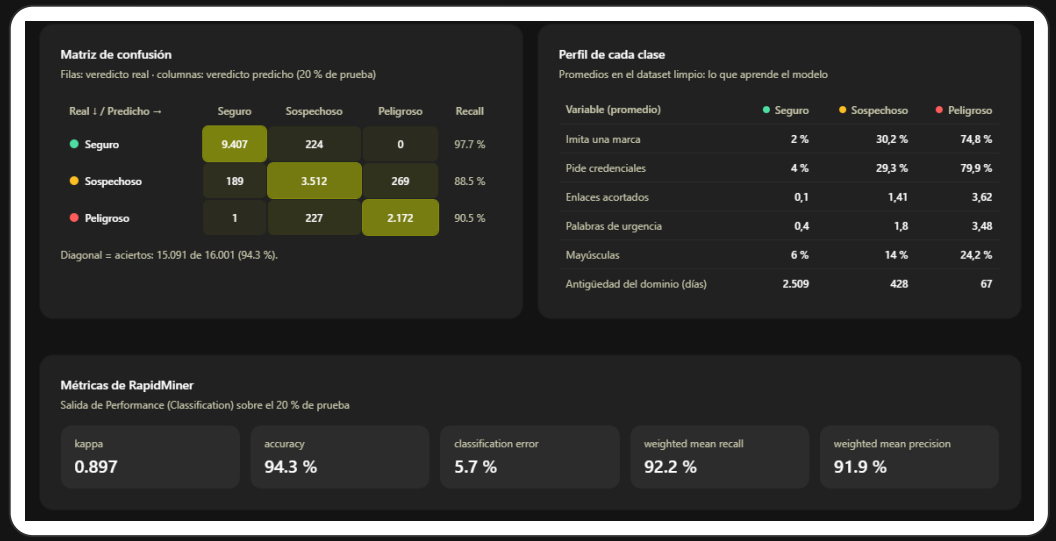
95 % de confianza media al acertar frente a 81 % al fallar: el modelo «sabe» cuándo duda.

FASE 6 · VISUALIZACIÓN

Los resultados viven en el panel de Mail Guard



Indicadores, flujo del proceso, embudo de depuración y distribución de la etiqueta.



- Embudo, faltantes y outliers por variable
- Matriz de confusión con recall por clase
- Perfil de cada clase y métricas de RapidMiner
- Se actualiza con cada ejecución del proceso

REQUERIMIENTOS

Todo lo que pidió el proyecto, con evidencia

	Requisito	Cómo se cumplió	Evidencia
✓	**Conectar la herramienta al objetivo**	RapidMiner conectado a Supabase (PostgreSQL) para clasificar correos	mail-guard-mineria.rmp
✓	**100.000 registros**	Dataset sintético con semilla fija	tabla mineria_correos
✓	**80 % limpios · 10 % outliers · 10 % sucios**	80.000 · 10.000 · 4.000 vacíos + 3.000 NULL + 3.000 duplicados	resumen_generacion.json
✓	**Fase de depuración**	Remove Duplicates, Declare Missing Value, Filter Examples ×2	100.000 → 80.000
✓	**Modelado y predicción**	Árbol de decisión (gain ratio, profundidad 10)	16.001 predicciones
✓	**Entrenamiento 80 % · validación 20 %**	Split Data estratificado	63.999 / 16.001 · 94,31 %
✓	**Fase de visualización**	Árbol y matriz en RapidMiner + página «Minería» del panel	/dashboard/mineria

CONCLUSIONES

Transformar datos en decisiones es un proceso

La limpieza pesa tanto como el modelo

El 20 % de los datos no servía. Sin depuración, el árbol habría aprendido de valores imposibles.

Un modelo simple y explicable basta

Un árbol de decisión alcanza 94 % y cada predicción se puede justificar con reglas.

Reproducible de punta a punta

Misma semilla, mismos resultados. Cada ejecución reemplaza la anterior en Supabase.

Siguiente paso: entrenar con correos reales etiquetados por los usuarios de Mail Guard y comparar con Random Forest.

MATRIZ DE MADUREZ DIGITAL · DIMENSIÓN DATOS



MAIL GUARD

Gracias

¿Preguntas? Podemos ejecutar el proceso en vivo en RapidMiner y ver cómo se actualiza el panel.

github.com/Tatianayya3/uts-mail-guard · mineria-datos/